AMAZON ATHENA

Análisis de datos sin servidores

Presentado por: Valentín y Adargoma

¿QUÉ ES AMAZON ATHENA?

Es un servicio de **consultas interactivo** que permite analizar datos directamente en **Amazon S3** utilizando SQL estándar.

Sin Servidores (Serverless)

No hay infraestructura que gestionar ni clusters que configurar.

SQL Estándar

Utiliza motores de código abierto como Presto y Apache Hive.

Capa de Análisis

Herramienta clave en el ecosistema de datos de AWS.

¿PARA QUÉ SE UTILIZA?

Consultas Ad-hoc

Ideal para realizar preguntas rápidas a los datos sin necesidad de cargarlos en una base de datos tradicional.

Análisis de Logs

Procesamiento de registros de red, servidores web o eventos de seguridad en cuestión de segundos.

Business Intelligence

Conexión directa con herramientas de visualización para generar informes dinámicos y paneles de control.

Exploración de Datos

Primer paso fundamental para entender grandes volúmenes de información antes de su procesamiento avanzado.

CARACTERÍSTICAS PRINCIPALES

100% Serverless

Sin administración de parches, actualizaciones o escalado de clusters.

Pago por Consulta

Solo pagas por la cantidad de datos escaneados por cada consulta ejecutada.

Soporte Multiformato

Compatible con formatos modernos: JSON, CSV, Parquet, Avro y ORC.

Seguridad Integrada

Control de acceso mediante IAM y cifrado de datos en reposo y tránsito.

FLUJO DE DATOS EN ATHENA

01

Almacenar en S3

Los datos residen en cubos de S3 en formatos como CSV, JSON o Parquet.

02

Catalogar (Glue)

Se definen las tablas y esquemas en el Catálogo de Datos de AWS Glue.

03

Consultar SQL

El usuario ejecuta consultas SQL estándar desde la consola o API.

04

Resultados

Athena procesa en paralelo y guarda los resultados de vuelta en S3.

TECNOLOGÍAS RELACIONADAS

ALMACENAMIENTO

AMAZON S3

Actúa como el **Data Lake** principal. Es donde residen los archivos (CSV, JSON, Parquet) que Athena consultará de forma directa y económica.

METADATOS

AWS GLUE

Proporciona el **Catálogo de Datos**. Permite a Athena conocer la estructura, columnas y tipos de datos de los archivos guardados en S3.

VISUALIZACIÓN

QUICKSIGHT

La herramienta de **BI** de AWS. Se conecta a Athena para transformar los resultados de las consultas SQL en gráficos y tableros interactivos.

¿QUÉ PROBLEMAS RESUELVE?

SOLUCIÓN **Complejidad de ETL**

Evita procesos largos de extracción, transformación y carga para realizar análisis rápidos sobre datos en bruto.

SOLUCIÓN **Costes Fijos Elevados**

Elimina la necesidad de mantener clusters encendidos 24/7 cuando solo se requieren consultas ocasionales.

SOLUCIÓN **Silos de Datos**

Permite consultar los datos directamente donde residen (S3), sin necesidad de moverlos a sistemas propietarios.

SOLUCIÓN **Lentitud en el Análisis**

Reduce drásticamente el tiempo desde que el dato llega al Data Lake hasta que se obtiene una respuesta útil.

CASOS DE USO REALES

Análisis de Logs Web

Identificar errores 404 o patrones de tráfico sospechosos en registros de CloudFront o servidores Apache.

Informes de Ventas

Consultar archivos mensuales de transacciones en S3 para obtener ingresos por región sin bases de datos.

Datos de Sensores IoT

Analizar telemetría de dispositivos almacenada en formato JSON para realizar mantenimiento predictivo.

Auditoría y Seguridad

Revisar registros de AWS CloudTrail para investigar cambios críticos en la infraestructura de la nube.

VENTAJAS Y DESVENTAJAS

VENTAJAS

- ✓ **Facilidad de uso:** Solo requiere conocimientos de SQL estándar.
- ✓ **Escalabilidad:** Alta disponibilidad automática por diseño de AWS.
- ✓ **Bajo coste:** Sin gastos de mantenimiento, solo pagas por lo que usas.
- ✓ **Integración:** Conexión nativa con todo el ecosistema de AWS.

DESVENTAJAS

- ✗ **No es OLTP:** No apto para bases de datos transaccionales de aplicaciones.
- ✗ **Optimización:** El rendimiento depende críticamente del formato de los archivos.
- ✗ **Coste variable:** Difícil de predecir si no se filtran bien los datos escaneados.
- ✗ **Latencia:** No es ideal para consultas que requieren respuestas en milisegundos.

CONCLUSIÓN Y RESUMEN

DEMOCRATIZACIÓN

Permite que cualquier persona con conocimientos de SQL analice petabytes de datos sin complicaciones técnicas.

EFICIENCIA DE COSTES

Es una de las formas más económicas de procesar datos masivos, especialmente con formatos columnares como Parquet.

SIMPLICIDAD TOTAL

La herramienta de entrada perfecta para proyectos de análisis en la nube al eliminar la gestión de infraestructura.

AGILIDAD DE NEGOCIO

Reduce el tiempo de obtención de valor (Time-to-Insight) de días o semanas a solo unos segundos.

"Analiza tus datos en segundos, no en días"